

# Rüzgar Türbinlerinde Olağandışılık Sezimi

## Anomaly Detection on Wind Turbines

Onur Poyraz  
Hesaplamalı Bilim ve Mühendislik  
Boğaziçi Üniversitesi  
34352 Bebek, İstanbul, Türkiye  
onur.poyraz@boun.edu.tr

M. Burak Kurutmaz ve A. Taylan Cemgil  
Bilgisayar Mühendisliği  
Boğaziçi Üniversitesi  
34352 Bebek, İstanbul, Türkiye  
{burak.kurutmaz, taylan.cemgil}@boun.edu.tr

Sinan Selamoğlu  
Borusan ARGE A.Ş.  
Büyükhanlı Plaza Kat:1  
34750 Ataşehir, İstanbul, Türkiye  
sselamoglu@borusan.com

**Özetçe** —Rüzgar türbinlerinin enerji üretimindeki paylarının artmasıyla beraber önemleri de gittikçe artmaktadır. Enerji üretiminin kesintiye uğraması önemli üretim kayıplarına sebep olduğundan türbinlerin mümkün olduğunca kesintisiz çalışması gerekir. Dolayısıyla türbin bakım ve onarımlarının doğru zamanda yapılabilmesi için rüzgar türbinlerinde olağandışılık sezimi önemlidir. Önceki çalışmalarda iki boyutlu güç eğrileri üzerinden çözümler yapılmıştır. Bu çalışmada ise türbinin olağan çalışma örüntüsü üç boyutlu güç eğrisi üzerinden Saklı Markov Modeli kullanılarak zaman serisi olarak öğrenilmektedir. Türbinin olağan örüntüsünde çalışıp çalışmadığı ise gelen verinin kestirimci dağılımının çözümlenmesi yapılarak tespit edilmektedir.

**Anahtar Kelimeler**—güç eğrisi, saklı markov modeli, öngörücü bakım, olağandışılık sezimi, kestirimci dağılım

**Abstract**—Wind turbines have become increasingly important as the share of energy production increases. Since the interruption of energy production leads to significant production losses, these turbines must operate as smoothly as possible. Therefore, anomaly detection on wind turbines is crucial so that turbine maintenance and repairs can be made at the right time. In the previous studies, two-dimensional power curves were analyzed. In this study, the regular working pattern of the turbine is learned as a time series by using Hidden Markov Model over the three-dimensional power curve. Whether the turbine works on its regular pattern or not is determined by analyzing the predictive distribution of the incoming data.

**Keywords**—power curve, hidden markov model, predictive maintenance, anomaly detection, predictive distribution

### I. GİRİŞ

Yenilenebilir enerji, gün ışığı veya rüzgar gibi doğal olarak tazelenen kaynaklardan ortaya çıkan enerji biçimidir. Geleneksel biokütle sınırlı olduğundan ve kullanımdan kaynaklanan atıklar çevreye zarar verdiğinden, yenilenebilir enerji son yıllarda oldukça popüler hale gelmiştir. Bu bağlamda, rüzgar dünyadaki en önemli yenilenebilir enerji kaynaklarından biridir. REN21 [1] raporuna göre rüzgar enerjisi, enerji üretiminde kullanılan yenilenebilir enerji kaynaklarının yüzde 53'ünü oluşturmaktadır ve bu oran giderek artmaktadır (hidroelektrik bu hesaplama dahil değildir).

Rüzgar türbinleri, hava hareketlerindeki kinetik enerjiyi elektriğe dönüştüren aygıtlardır. Göreli olarak rüzgar, bütün

yenilenebilir enerji kaynakları arasında en düşük sera gazı salınımına sahiptir [2]. Bu nedenle de kullanımı diğer alternatif enerji kaynaklarından daha hızlı artmaktadır. Rüzgar türbinleri elektriğin gerekli olduğu her alanda kullanılabilir. Büyük ve pahalı aygıtlar olduklarından, rüzgar çiftlikleri inşa etmek ve üretilen gücü şebekeye vermek en verimli yöntemdir. Öte yandan rüzgar hızları genel olarak çok yüksek olmadığı için rüzgar türbinlerinin yüzey alanlarının büyük olması gerekir. Bunun sonucu olarak büyük fiziksel bileşenlerden oluşurlar. Dolayısıyla bu aygıtlardaki arızaları onarmak zor ve pahalıdır. Rüzgar türbinleri kuramsal verimlilik sınırlarına ve ideal tasarımına henüz ulaşmamıştır. Başka bir deyişle teknolojik olarak gelişmekte olan aygıtlardır. Bütün bunların bir sonucu olarak, rüzgar türbinlerinin bakım ve onarım maliyetlerini azaltmak adına olağan çalışma örüntülerinin öğrenilmesi ve ortaya çıkan arızalarının çözümlenmesi büyük önem taşımaktadır.

Rüzgar türbinlerinin çalışma ilkelerini çözümlmek için çok sayıda yaklaşım vardır. Kusiak v.d. [3], *rastgele orman* (random forest) algoritmasıyla sistemin olağan çalışma örüntüsünü öğrenen ve türbin durumlarını sınıflandıran bir model önermişlerdir. Türbin normal çalışma koşullarının dışına çıkarsa, algoritmaları buna karşılık gelen uyarıyı üretir. Yang v.d. [4], *Gözcü Kontrol ve Veri Toplama* (Supervisory Control and Data Acquisition - SCADA) verilerinin istatistiksel çözümlenmesini yapmak için ön işleme olarak *topaklandırma* (clustering) yöntemini kullanıp daha sonra türbin çalışma değerlerini kestirmek için *en küçük kareler* (least squares) yöntemiyle *çok terimli uyumlama* (polynomial regression) yapmışlardır. Algoritmaları da bu *değiştirgelere* (parametrelere) göre türbinin normal durumda ya da hatalı durumda olduğuna karar verir. Başka bir çalışmada Ouyang v.d. [5], *Destek Vektör Makineleri* (Support Vector Machine - SVM) kullanarak rüzgar hızı - üretilen güç verisinden oluşturulmuş güç eğrisini çözümlen bir model önermişlerdir. Kusiak v.d. [6] başka bir çalışmada, yapay sinir ağlarıyla güç eğrisini çözümlenmişlerdir. Kontrol durumu olarak, türbinlerin kontrol/hata bildirimini kullanıp türbinin ürettiği negatif enerji üzerinden bakım süreleri ile ilgili tahminlerde bulunmuşlardır. Kim v.d. [7], güç eğrilerini çözümlmek için *kendini örgütleyen haritalar* (self-organizing maps - SOM) kullanarak, başarısızlık veya performans sorunları konusunda uyarı üretmeyi denemişlerdir. Şu ana kadar bahsettiğimiz yöntemler rüzgar türbininin SCADA algılayıcılarından elde edilen rüzgar hızı - güç ilişkisini kullanırlar. Döneç hızı gibi, türbin ile doğrudan ilgili herhangi bir verinin kullanılmaması bu çalışmaların eksik kısmını oluşturur. Romero v.d. [8], anlattığımız önceki çalışmalardan farklı olarak

hem SCADA hem de *Durum Görüntüleme Sistemi* (Condition Monitoring System - CMS) verileriyle iki adımlı arıza tespiti yapmışlardır. İlk adımda döneç hızı - üretilen güç arasındaki ilişkiyi inceleyen bir güç eğrisi modeli kullanılırken ikinci adımda CMS verisi kullanılarak bir titreşim çözümlemesi yapılmıştır. İlk adımdaki hata uyarılarını ikinci adımdaki çözümlemeleriyle doğrulamışlardır.

Yukarıda bahsedilen çalışmaların hiçbiri, güç eğrisini bir zaman serisi olarak değerlendirmedikleri için türbinin önemli bir çalışma ilkesini göz ardı etmişlerdir. Dolayısıyla güç eğrisini çok boyutlu ele alabilen ve güç eğrisine zaman serisi olarak yaklaşabilen bir yöntem yenilikçi bir yaklaşıma sahip olacaktır. Bu çalışmada güç eğrisinin tanımlanan özelliklerini dikkate alan *Saklı Markov Modeli* (Hidden Markov Model - HMM) temelli istatistiksel bir yöntem öneriyoruz.

## II. RÜZGAR TÜRBİNİ İÇİN GÜÇ EĞRİSİ MODELİ


Rüzgar türbinlerinin güç eğrisi, rüzgar veya döneç hızının veya her ikisinin birlikte güç üretimiyle olan ilişkisini tanımlar. Fiziksel makinenin karmaşık bir kontrol mekanizması olduğu gibi, doğrudan ölçülebilir olmayan çevresel değişiklikler bu ilişkiyi daha da karmaşık hale getirmektedir. Bu nedenle, farklı koşullar altında rüzgar türbinlerinin temel çalışma ilkelerini göz önünde bulunduran bir model oluşturulmalıdır. Bu amaçla, rüzgar türbininin güç eğrisini verimli bir şekilde çözümlemek için istatistiksel yöntemler kullanıyoruz.

Güç eğrisinin modellenmesi için farklı yaklaşımlar vardır. Bazı çalışmalarda [5]–[7] güç eğrisini değerlendirmek için rüzgar hızı ve üretilen güç, bazılarında [8] ise döneç hızı ve üretilen güç kullanılmıştır. Rüzgar hızı ve güç birbiriyle doğrudan ilişkili görünse de zaman içinde rüzgar hızındaki ani değişikliklere karşılık üretilen gücün durağanlığı rüzgar hızı - güç eğrisindeki *değişintiyi* (varyansı) arttırmaktadır. Benzer bir durum, döneç hızı - güç eğrisi için de geçerlidir. Ayrıca rüzgar türbinleri dönen *dizgeler* (sistemler) olduğundan, artan hız ile üretim değişintisinin artacağını da belirtmek gerekir. Dolayısıyla ne rüzgar hızı ne de döneç hızı tek başına üretilen gücü açıklamak için yeterli değildir. Bunlara ek olarak, üretilen gücün açıklanmasında türbinin zaman içindeki davranışı da göz ardı edilemez. Bu nedenle güç eğrisini, *Şekil 1*'deki gibi rüzgar hızı ve döneç hızının birlikte kullanıldığı bir zaman serisi olarak modelliyoruz. Bu seçim sonucunda, güç eğrisinin boyutsallarını birbirlerinin eksikliklerini kapatan özneliliklerle arttırmanın güç eğrisindeki yüksek *değişintiyi* azalttığını ve güç eğrisi içerisindeki değişim eğilimlerinin daha kolay çözümlenebildiğini gözlemliyoruz.

Bu çalışmada her bir türbin için ayrı ayrı en iyi (optimum) model değiştirgelerini bulmayı hedefliyoruz, çünkü fiziksel makineler gibi karmaşık sistemler tam olarak aynı mekanizma ile çalışsalar bile farklı üretim örüntüleri gösterebilirler. Ancak güç eğrisi içerisindeki değişim eğilimlerinin birbirleriyle karşılaştırılmasıyla türbin çiftliğinin de sağlığı kontrol edilebilir.

## III. SAKLI MARKOV MODELİ

Bu çalışmadaki asıl amaç rüzgar türbinlerinin bozulma evresinde uyarı veren bir dizge geliştirmektir. Ancak rüzgar türbinleri çok sık arızalanan aygıtlar olmadıkları için elimizde bozulma evresini modellemek veya geçerlemek (validation) için yeteri kadar veri bulunmamaktadır. Bu nedenle, her bir



**Şekil 1:** Rüzgar hızı, döneç hızı ve üretilen güç kullanılarak oluşturulmuş üç boyutlu güç eğrisi

rüzgar türbininin olağan çalışma evresindeki davranışı modellenmiş ve bunun dışında çalışması durumunda uyarı verecek bir dizge geliştirilmiştir.

Her bir rüzgar türbininin davranışı bir *Saklı Markov Modeli* [9] olarak modellenmektedir. Bu modelde, her zaman diliminde türbinin *ayrık bir durum uzayından* (discrete state space) kendisine bir durum seçtiği ve bu duruma göre rüzgar hızı, döneç hızı ve üretilen güç gibi gözlemler oluşturduğu varsayılmaktadır. Türbinin her zaman diliminde seçtiği durum ise sadece bir önceki durumuna bağlıdır. Bu durum uzayı, sezgisel olarak türbinin çalışma sırasında girdiği evrelere (kapalı olma, en fazla güç üretme gibi) karşılık gelmektedir. Ancak problemin başlıca zorluklarından biri, veri kümesi içinde türbinin evreleri gibi bir özneliliğin bulunmamasıdır. Dolayısıyla, bu durum uzayının gözetimsiz bir öğrenme algoritmasıyla bulunması gerekmektedir. Ayrıca veri kümesinde algılayıcılardan kaynaklanan bazı *eksik gözlemler* ve *aykırı değerler* (outliers) de bulunmaktadır. Bunlar da problemde karşılaşılan ve Saklı Markov Modelinde hesaba katılması gereken diğer etkenlerdir.

Modeldeki  $n$ 'inci gözlemi  $X_n$ , buna karşılık gelen saklı değişkeni yani  $n$ 'inci durumu ise  $S_n$  ile göstereceğiz. Gözlemler, türbinin algılayıcılarından ölçülen rüzgar hızı, döneç hızı ve üretilen güç değerleri olduğu için  $X_n = [W_n \ R_n \ P_n]^T$  şeklinde uzunluğu 3 olan bir vektör olarak ifade edilecektir. Burada  $W_n$ ,  $R_n$  ve  $P_n$  sırasıyla  $n$ 'inci zaman dilimindeki rüzgar hızı, döneç hızı ve üretilen güce karşılık gelmektedir.

### A. Üreteç Model ve Öğrenme

Rüzgar türbininin ayrık durum uzayı, olağan çalışma evrelerini belirten  $K$  farklı durum ve aykırı değerlerin görüldüğü 1 durumdan oluşmaktadır. Aslında, aykırı gözlemlerin modellenmesi için ayrı bir durum tanımlamak yerine gözlem modeli değiştirilerek her gözlemin küçük bir olasılıkla çok gürültülü olarak gözlemlendiği de varsayılabilir. Ancak veriden gördüğümüz kadarıyla aykırı değerlerin arka arkaya görülmesi daha olasıdır. Bu nedenle, durum uzayı bu şekilde tanımlanmıştır.

Modelimizde durumlar arası geçişlerin olasılıkları  $\pi \in \mathbb{R}^{(K+1) \times (K+1)}$  değiştirgesi ile gösterilmektedir. Bir diğer deyişle,  $j$ 'inci durumdan  $i$ 'inci duruma geçişin olasılığı  $\pi_{ij}$ 'dir. Her bir durumun da kendine ait bir gözlem dağılımı vardır. Aykırı değerlerin görüldüğü durumun ( $i = 0$ ) gözlem dağılımı, güç eğrisinin içinde bulunduğu sınırlı aralıkta tanımlı bir *tekdüze* (uniform) dağılımdır. Diğer durumların ( $i > 0$ ) gözlem dağılımları da değiştirgeleri  $\mu^{(i)}$  ve  $\Sigma^{(i)}$  olan *çok değişkenli*

Gauss dağılımlarıdır:

$$p(S_n = i | S_{n-1} = j) = \pi_{ij} \quad p(S_1) = \mathcal{U}\{0, K\}$$

$$p(X_n | S_n = i) = \begin{cases} c, & i = 0 \\ \mathcal{N}(X_n; \mu^{(i)}, \Sigma^{(i)}), & i > 0 \end{cases}$$

Bir sonraki aşama ise  $\pi$ ,  $\mu^{(i)}$  ve  $\Sigma^{(i)}$  değıştirmelerinin veriden çıkarsanmasıdır. Bu işlemi tüm veri kümesi üzerinden yapmak masraflı olacağından veri kümesinin içinden  $N$  uzunluğunda rastgele diziler seçilebilir. Seçilen  $t$ 'inci dizi  $X_{1:N}^{(t)}$  olsun ve bu dizi için  $S_{1:N}^{(t)}$ 'lerin bilindiğini varsayalım. O zaman, değıştirmelerin *yeterli istatistikleri* (sufficient statistics) aşağıdaki gibi hesaplanabilir:

$$\langle X_n X_n^T \rangle_{p(X_n | S_n = i)} \approx \mathcal{V}_t^{(i)} = \frac{\sum_{n=1}^N [S_n^{(t)} = i] X_n X_n^T}{\sum_{n=1}^N [S_n^{(t)} = i]} \quad (1)$$

$$\langle X_n \rangle_{p(X_n | S_n = i)} \approx m_t^{(i)} = \frac{\sum_{n=1}^N [S_n^{(t)} = i] X_n}{\sum_{n=1}^N [S_n^{(t)} = i]} \quad (2)$$

$$C_{ij}^{(t)} = \sum_{n=1}^{N-1} [S_n^{(t)} = j] [S_{n+1}^{(t)} = i] \quad (3)$$

Seçilen her dizi için bulunan yeterli istatistik ( $\mathcal{V}_t^{(i)}$ ,  $m_t^{(i)}$ ,  $C_{ij}^{(t)}$ ) değierlerinin ortalaması alınarak nihai  $\mathcal{V}^{(i)}$ ,  $m^{(i)}$  ve  $C_{ij}$  kestirimi yapılabilir. Bu işlemin daha az maliyetle yapılabilmesi için  $[0, 1]$  aralığında bir  $\eta_t$  değıştirgesi seçilerek *sıralı ortalamalar* (online average) hesaplanabilir. Bulunan yeterli istatistiklerden, dağılımların değıştirmelerinin kestirimi ise aşağıdaki gibi olacaktır:

$$\pi_{ij} \approx C_{ij} / \sum_k C_{kj} \quad \Sigma^{(i)} \approx \mathcal{V}^{(i)} - m^{(i)} m^{(i)T} \quad \mu^{(i)} \approx m^{(i)}$$

1, 2 ve 3'teki formüllerin hesaplanabilmesi için  $S_{1:N}^{(t)}$  durumları bilinmelidir. Eğer  $\pi$ ,  $\mu^{(i)}$  ve  $\Sigma^{(i)}$  değıştirmeleri bilinirse, *Viterbi* [9] algoritmasıyla izleyen özyinelemeli eşitlik kullanılarak  $S_{1:N}^{(t)}$  kestirimi yapılabilir:

$$\underbrace{\max_{S_{1:n-1}^{(t)}} p(S_{1:n}^{(t)}, X_{1:n})}_{\phi_n(S_n^{(t)})} = p(X_n | S_n^{(t)}) \max_{S_{n-1}^{(t)}} \left( p(S_n^{(t)} | S_{n-1}^{(t)}) \underbrace{\max_{S_{1:n-2}^{(t)}} p(S_{1:n-1}^{(t)}, X_{1:n-1})}_{\phi_{n-1}(S_{n-1}^{(t)})} \right)$$

Dolayısıyla, önce durumları ( $S_{1:N}^{(t)}$ ) sabit kabul edip değıştirmeler ( $\pi$ ,  $\mu^{(i)}$ ,  $\Sigma^{(i)}$ ) üzerinden *enbüyükleme* yapan sonra da değıştirmeleri sabit kabul edip durumlar üzerinden *enbüyükleme* yapan yinelemeli bir algoritma ile istenilen değıştirmeler çıkarsanabilir.

*Eksik veri* olması durumunda değışecek olan tek şey gözlem dağılımıdır. Neyse ki, Gauss dağılımı ve tekdüze dağılımın avantajlı özelliklerinden biri *bileşen olasılıklarının* (marginal probability) kolayca hesaplanabilmesidir. Örneğin; döneç hızının gözlemlenmediği durumda, *birleşik dağılımı* (joint distribution) Gauss olan dağılımlar,  $\mu^{(i)}$  ve  $\Sigma^{(i)}$ 'den döneç hızına ilişkin tüm satır ve sütunların çıkarılmasıyla elde edilen 2 boyutlu Gauss dağılımlarına dönüşecektir.

## B. Kestirimci Dağılımın Hesaplanması

Bir önceki bölümde türbinin olağan çalışma örüntüsünün öğrenilmesi işlemini gerçekleştirdik. Bundan sonra yapılması gereken ise gözlemlenen davranışın eğitilen model ile değierlendirilmesi olacaktır. Sezgisel olarak türbinin olağan çalışma örüntüsünden farklı çalışması, türbinden toplanan gözlemlerin öğrenilen modelle öngörülememesine denk gelmektedir. Doğal olarak *kestirimci dağılımın* (predictive distribution) hesaplanması bunu nicelemenin en verimli yollarından biridir. Buradaki önemli nokta  $X_n$ 'in kestirimci dağılımı  $p(X_n | X_{1:n-1})$  yerine sadece döneç hızı ve gücün, rüzgara koşullu kestirimci dağılımı  $p(R_n, P_n | W_n, X_{1:n-1})$ 'in daha anlamlı olmasıdır. Çünkü türbinin davranışı, verilen dış koşullar (rüzgar hızı) altında nasıl çıktılar (döneç hızı ve güç) ürettiğidir.

Döneç hızı ve üretilen gücün, rüzgara koşullu kestirimci dağılımı altında tüm gözlemin kestirimci dağılımının rüzgarın kestirimci dağılımına oranıdır:

$$p(R_n, P_n | W_n, X_{1:n-1}) = \frac{p(X_n | X_{1:n-1})}{p(W_n | X_{1:n-1})}$$

Tüm gözlemin ve rüzgarın kestirimci dağılımları da izleyen özyinelemeli eşitliklerle hesaplanabilir:

$$p(X_n | X_{1:n-1}) = \sum_{S_n} p(X_n | S_n) \sum_{S_{n-1}} p(S_n | S_{n-1}) p(S_{n-1} | X_{1:n-1})$$

$$p(W_n | X_{1:n-1}) = \sum_{S_n} p(W_n | S_n) \sum_{S_{n-1}} p(S_n | S_{n-1}) p(S_{n-1} | X_{1:n-1})$$

Bu denklemlerdeki  $p(S_{n-1} | X_{1:n-1})$  olasılıklarının bulunması içinse *ileri yön olasılıklarının* (forward probabilities) [9] bulunup düzleştirilmesi (normalizasyon) yeterlidir. İleri yön olasılıkları da izleyen özyinelemeli eşitlikle bulunabilir:

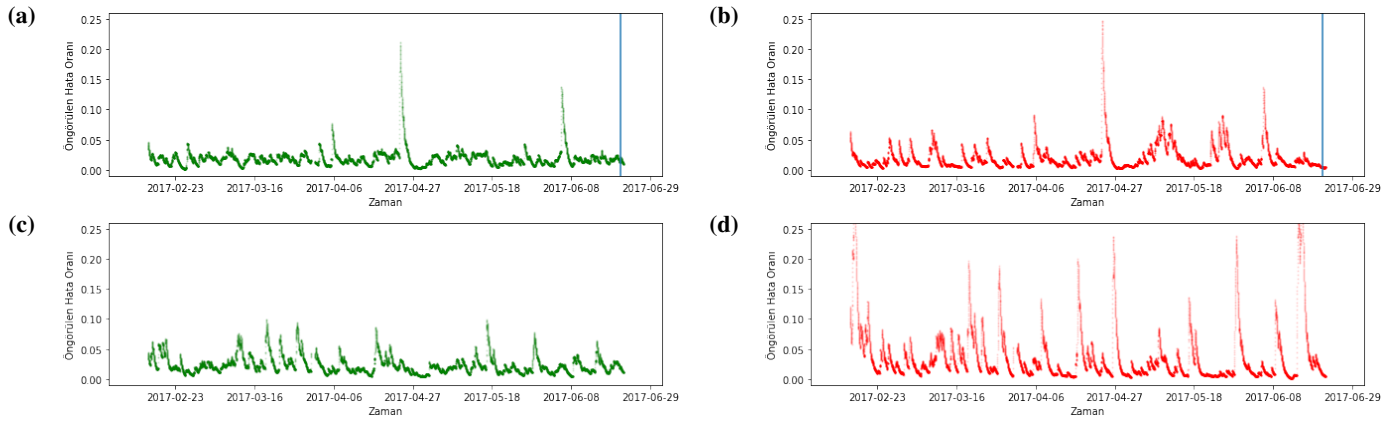
$$\underbrace{p(S_n, X_{1:n})}_{\alpha_n(S_n)} = p(X_n | S_n) \sum_{S_{n-1}} p(S_n | S_{n-1}) \underbrace{p(S_{n-1}, X_{1:n-1})}_{\alpha_{n-1}(S_{n-1})}$$

Son olarak, kestirimci dağılımdan hata öngörüsü  $E_n$  değierleri oluşturmak için HMM'in bulduğu kestirimci dağılımın performansı, döneç hızı ve gücün tanımlı olduğu uzaydaki tüm noktaları eşit olasılıklı olarak kestiren bir tekdüze dağılımın performansı ile karşılaştırılır. Tekdüze dağılımın bile HMM'den daha iyi kestirim yaptığı durumlarda aşağıdaki şekilde tanımlanmış olan  $E_n$  değierleri yüksek çıkacak ve dolayısıyla bu durumlar hata olarak öngörüülecektir:

$$E_n = a / (a + p(R_n, P_n | W_n, X_{1:n-1}))$$

## IV. DENEY VE SONUÇLAR

Bu çalışmada, *Vestas V90-3MW* rüzgar türbinlerinin SCADA veri kümesi kullanılmıştır. Bu veri kümesi 20 farklı türbine ait rüzgar hızı, döneç hızı ve üretilen güç değierlerinin 10'ar dakikalık örnekleme aralığında 2017 yılının Şubat ve Temmuz ayları arasında kesintisiz toplanmasıyla elde edilen 25737'şer gözlemden oluşmaktadır. Ayrıca veri kümesi, algılayıcılardaki anlık hatalardan kaynaklanan aykırı veya eksik



**Şekil 2:** HMM (yeşil) ve GMM’den (kırmızı) elde edilen hata öngörülerinin hareketli ortalamalarının karşılaştırılması. Arızaların tarihleri dikey mavi çizgiyle gösterilmiştir. Haziran ayında arızalandığı bilinen ilk türbin için: **(2a)** HMM arıza öncesinde iki tane belirgin olağandışılık öngörüsünde bulunurken **(2b)** GMM’in ürettiği öngörülerin daha zayıf ve gürültülü olduğu görülüyor. Herhangi bir arıza belirtisi göstermemiş olan ikinci türbin için: **(2c)** HMM belirgin bir olağandışılık öngörüsünde bulunmazken **(2d)** GMM çok sayıda yalancı pozitif olağandışılık öngörüsü yapıyor.

gözlemler de içermektedir. Model her bir türbin için, türbinin kendisine ait Mart ve Mayıs ayları arasında elde edilmiş 10000 gözlemle eğitilmiştir. Modeller verinin  $N = 400$  uzunluğunda mini diziler halinde işlenmesiyle eğitilmiştir. Eğitim sırasında  $T = 1000$  yineleme (iteration) boyunca öğrenme hızı olarak  $\eta_t = 1/(t + 1)$  olarak seçilmiştir.

Modelin performansı aynı durum uzayında tanımlanmış *Gauss Karışım Modeli* (Gaussian Mixture Model - GMM) ile karşılaştırılmıştır. Bu modelde de türbinin olağan çalışma evrelerini modelleyen ve gözlem dağılımı Gauss olan  $K$  tane durum ve aykırı değerlerin görüldüğü, gözlem dağılımı tekdüze olan 1 durum tanımlanmıştır. Bu modelin değişirgeleri ise *beklenti-enbüyütme* (Expectation-Maximization, EM) algoritmasıyla öğrenilmiştir. HMM’e göre daha basit olan bu modelin tek farkı zaman etkisini hesaba katmamasıdır.

Yapılan deneyler sonucunda modellerin 21 Haziran tarihinde arızalanan bir türbinde oluşturduğu hata öngörülerini olan  $E_n$  değerlerinin *hareketli ortalamaları* (moving average) *Şekil 2a* ve *Şekil 2b*’de gösterilmiştir. Bu grafiklerden HMM’in hata öngörüsünü GMM’e göre daha net yapabildiği sonucu çıkarılabilir. Bunun sebebi HMM’in belirli zaman aralıklarında türbinin olağan çalışma örüntüsünün dışında davrandığını tespit edebilmesidir. Ancak HMM’in asıl öne çıktığı nokta yalancı pozitif hata öngörüsünü büyük oranda azaltmasıdır. Arızalanmamış bir türbindeki hata öngörülerinin hareketli ortalamaları olan *Şekil 2c* ve *Şekil 2d*’ye bakıldığında GMM yalancı pozitif hata öngörülerinde bulunurken HMM’in bu konuda çok daha başarılı olduğu görülmektedir. Çünkü GMM hata öngörüsünü anlık gözlemler üzerinden yaparken HMM hata öngörüsünü gözlemlerin zaman içerisindeki evrilmesine göre yapmaktadır. Dolayısıyla algılayıcılardaki anlık aykırı ve eksik gözlemlere karşı daha az duyarlıdır.

## V. VARGILAR

Rüzgar türbinlerinde olağandışılık sezimi için yapılan önceki çalışmalarda rüzgar türbinlerinin güç eğrileri modellenmiştir ancak geliştirilen modellerin hiçbirisinde güç eğrileri bir zaman serisi olarak ele alınmamıştır. Yapay sinir ağları, kendini örgütleyen haritalar, destek vektör makinaları, çok terimli uyumlama gibi farklı yöntemler kullanılmasına rağmen

bu çalışmaların tamamında güç eğrisinin zamana olan bağıllığı göz ardı edilmiştir. Bu nedenle geliştirilen modellerin yanlış pozitif öngöründe bulunma olasılıkları daha yüksektir. Bu çalışmada ise güç eğrisi Saklı Markov Modeliyle çözümlenip olağan çalışma örüntüsü öğrenilmiştir. Bu sayede güç eğrisinin zamanla olan ilişkisini de göz önünde bulunduran bir model oluşturulmuştur. Öğrenilen modelden hesaplanan kestirimci dağılım aracılığıyla da hata öngörülerini yapılmıştır.

Bundan sonraki çalışmalarda rüzgarın yönü ve türbin bileşenlerinin sıcaklığı gibi değişkenlerin özniteliklere eklenmesiyle daha etkili öngörülerin yapılması amaçlanmaktadır. Ayrıca çevresel koşullarda meydana gelen olağandışı olaylar hata öngörülerini negatif etkileyebilir. Bunun da üstesinden gelebilmek adına türbinlerin aynı zaman dilimlerindeki öngörülerini kıyaslanarak model sonuçlarına eklenebilir.

## KAYNAKLAR

- [1] R. S. Committee *et al.*, “Renewables 2017, global status report,” *Renewable Energy Policy Network for the 21st Century*, 2017.
- [2] A. Evans, V. Strezov, and T. J. Evans, “Assessment of sustainability indicators for renewable energy technologies,” *Renewable and Sustainable Energy Reviews*, vol. 13, no. 5, pp. 1082–1088, 2009.
- [3] A. Kusiak and A. Verma, “Prediction of status patterns of wind turbines: A data-mining approach,” *Journal of Solar Energy Engineering*, vol. 133, no. 1, p. 011008, 2011.
- [4] W. Yang, J. Jiang *et al.*, “Wind turbine condition monitoring by the approach of scada data analysis,” *Renewable Energy*, vol. 53, pp. 365–376, 2013.
- [5] T. Ouyang, A. Kusiak, and Y. He, “Modeling wind-turbine power curve: A data partitioning and mining approach,” *Renewable Energy*, vol. 102, pp. 1–8, 2017.
- [6] A. Kusiak and W. Li, “The prediction and diagnosis of wind turbine faults,” *Renewable Energy*, vol. 36, no. 1, pp. 16–23, 2011.
- [7] K. Kim, G. Parthasarathy, O. Uluyol, W. Foslien, S. Sheng, and P. Fleming, “Use of scada data for failure detection in wind turbines,” in *ASME 2011 5th International conference on energy sustainability*. American Society of Mechanical Engineers, 2011, pp. 2071–2079.
- [8] A. Romero, Y. Lage, S. Souza, B. Wang, and T.-H. Gan, “Vestas v90-3mw wind turbine gearbox health assessment using a vibration-based condition monitoring system,” *Shock and Vibration*, vol. 2016, 2016.
- [9] L. R. Rabiner, “A tutorial on hidden markov models and selected applications in speech recognition,” *Proceedings of the IEEE*, vol. 77, no. 2, pp. 257–286, 1989.